Trabajo Práctico de R

Examen Domiciliario

Universidad Torcuato Di Tella

Laboratorio de Análisis de Datos

Integrantes:
Juan Pablo Cardozo
Irene Kozicki

Profesores:
Ian Evangelos Bounos
Pedro Dolanyi Plaza

Octubre de 2026

1. Análisis de Datos: Producción de Soja en Argentina

1.1. Contexto y Descripción del Conjunto de Datos

Para el desarrollo del ejercicio de análisis de datos se utilizó el registro histórico oficial sobre la producción agrícola de soja en Argentina, obtenido a través del portal de datos abiertos del Estado Argentino (Datos.gob.ar). El conjunto de datos abarca una serie temporal anual continua desde el año 1941 hasta el año 2024 (84 observaciones en total).

La estructura del *dataframe* contempla cinco variables principales que caracterizan la evolución del cultivo en el país:

- `indice_tiempo`: Año correspondiente (1941–2024).
- `superficie_sembrada_soja_ha`: Superficie total implantada con soja, medida en hectáreas (ha).
- `superficie_cosechada_soja_ha`: Superficie efectivamente recolectada, medida en hectáreas (ha).
- `produccion_soja_t`: Volumen total de grano cosechado, medido en toneladas (t).
- `rendimiento_soja_kgxha`: Productividad por unidad de superficie, medida en kilogramos por hectárea (kg/ha).

1.2. Inspección Exploratoria y Calidad de los Datos

Con el fin de garantizar la reproducibilidad del experimento, se fijó una semilla al inicio del *script* mediante el comando `set.seed(345)`. Posteriormente, se cargó la base de datos y se realizó un chequeo sistemático de integridad para verificar la ausencia de valores faltantes (NAs) o registros atípicos mediante las funciones `colSums(is.na(datos_soja))` y `summary(datos_soja)`.

El conteo de celdas vacías arrojó exactamente cero en todas las variables, confirmando la validez del conjunto de datos. En la Cuadro 1 se presentan los estadísticos descriptivos fundamentales derivados de la inspección inicial.

Cuadro 1: Estadísticos descriptivos del conjunto de datos de Soja (1941–2024)

Variable	Mínimo	1er Cuartil	Mediana	Media	3er Cuartil	Máximo
Sembrada (ha)	400	12.840	2.641.000	6.234.978	14.421.249	20.562.233
Cosechada (ha)	227	11.577	2.595.350	6.051.606	14.093.835	19.590.871
Producción (t)	268	13.305	5.325.000	15.742.571	31.099.090	61.398.276
Rendimiento (kg/ha)	614,1	1.140,2	1.942,0	1.867,7	2.470,4	3.334,0

Como refleja el cuadro resumen, la serie histórica muestra la profunda evolución del sector: mientras que en los primeros registros la producción resultaba marginal (mínimo histórico de 268 toneladas), el sector llegó a superar techos de 61,39 millones de toneladas con rendimientos de hasta 3.334 kg/ha.

1.3. Pregunta 1: Evolución de la Producción Total y el Rendimiento

Para responder a la primera pregunta de investigación sobre la trayectoria histórica del cultivo, se identificaron los años con los niveles extremos de producción nacional utilizando las funciones `arrange()` y `slice(1)` sobre las variables de volumen cosechado y rendimiento agrícola.

1.3.1. Valores Extremos e Hitos Históricos

- **Mínimo Histórico (Año 1945):** Se registró un volumen de producción total de tan solo **268 toneladas**, cosechadas sobre una superficie de 227 hectáreas (de un total sembrado de 400 ha), alcanzando un rendimiento medio de $1{,}180,62$ kg/ha. Este valor refleja la etapa incipiente e experimental del cultivo en el país durante la primera mitad del siglo XX.
- **Maximo Histórico (Año 2014):** Se alcanzó una producción máxima registrada en la serie de **61.398.276 toneladas** ($61,39$ millones de toneladas), con una superficie cosechada de 19,334,915 ha (de 19,792,100 ha sembradas) y un rendimiento medio de $3{,}175,51$ kg/ha.

1.3.2. Análisis Gráfico del Rendimiento Agrícola

A fin de analizar la eficiencia productiva de la tierra a lo largo del tiempo, se graficó la evolución del rendimiento por hectárea (`rendimiento_soja_kgxha`) entre 1941 y 2024 utilizando el paquete `ggplot2`.

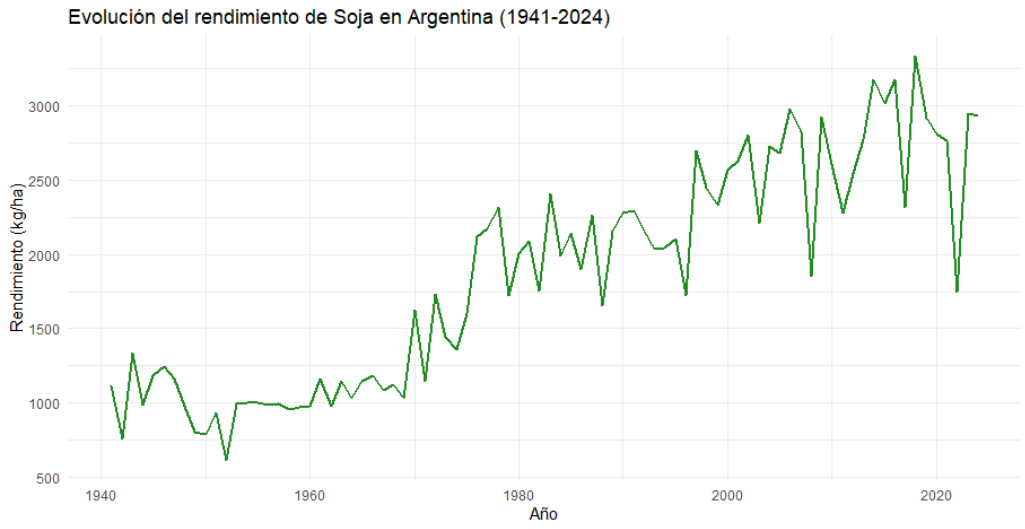


Figura 1: Evolución del rendimiento de Soja en Argentina (kg/ha), 1941–2024.

Como se observa en la Figura 1, el rendimiento por hectárea presenta tres fases históricas claramente diferenciadas:

1. **Fase de Estancamiento e Inicio (1941–1970):** Los rendimientos oscilaron en niveles bajos, inferiores a los 1,200 kg/ha, debido a la reducida escala y falta tecnologia

2. **Fase de Expansión Agrícola (1970–1995):** Se verifica una pendiente fuertemente positiva en la productividad, pasando de 1,000 kg/ha a superar los 2,200 kg/ha hacia mediados de los años noventa.

3. **Fase Biotecnológica y Volatilidad Climática (1996–2024):** Los rendimientos alcanzaron promedios superiores a los 2,500–3,000 kg/ha, alcanzando picos máximos cercanos a los 3,300 kg/ha.

1.4. Pregunta 2: Proporción de la Superficie Sembrada Cosechada y Años Críticos

Para analizar la efectividad de la cosecha en relación con la superficie sembrada, se creó la variable relativa `pct_cosechado` utilizando la función `mutate()`:

$$\text{pct_cosechado} = \left(\frac{\text{superficie_cosechada_soja_ha}}{\text{superficie_sembrada_soja_ha}} \right) \times 100 \tag{1}$$

1.4.1. Promedio Histórico General

A partir del cálculo general sobre la serie temporal (1941–2024), se obtuvo que el porcentaje medio de superficie cosechada sobre sembrada en Argentina fue del **89,22 %**. Esto indica que, en promedio histórico, cerca del $10,78\,\%$ de la superficie implantada se pierde anualmente debido a contingencias climáticas (sequías, Inundaciones o heladas).

1.4.2. Identificación de Años Críticos ($< 80\,\%$ Cosechado)

Se filtraron mediante la función `filter()` aquellos períodos excepcionales en los que la efectividad de la cosecha fue inferior al $80\,\%$ (`pct_cosechado <80`). En la Cuadro 2 se detallan los registros resultantes.

Cuadro 2: Años críticos con menos del $80\,\%$ de superficie cosechada

Año (`indice_tiempo`)	**Superficie Cosechada (%)**
1942	76,10 %
1944	74,57 %
1945	56,75 %
1946	27,88 %
1947	34,89 %
1948	37,30 %
1949	72,16 %
1951	79,01 %
1953	56,91 %
1954	50,00 %
1955	50,00 %
1956	55,08 %
1957	56,26 %

Como se desprende de los resultados, los años con pérdidas extremas de superficie concentran su presencia en la década de 1940 y 1950 (llegando a mínimos históricos en

1946 con solo un $27,88\,\%$ cosechado). Esto se explica principalmente por las dificultades técnicas, falta de maquinaria adecuada e inexperiencia en el manejo del cultivo durante las etapas iniciales de introducción de la soja en el país.

1.5. Pregunta 3: Análisis del Salto Tecnológico (Era Pre vs. Post Soja Transgénica, 1996)

Para evaluar si existió una aceleración en el rendimiento y la producción agrícola a partir de la adopción masiva de la biotecnología (aprobación del evento de soja transgénica en Argentina en el año 1996), se dividió la serie histórica en dos subperíodos mediante la función `filter()`:

1. **Período Pre-Transgénica (1941–1995):** Comprende las primeras 55 observaciones de la serie.
2. **Período Post-Transgénica (1996–2024):** Comprende las 29 observaciones más recientes.

1.5.1. Cuadro Comparativo de Medias

Se calcularon los promedios del rendimiento por hectárea (`rendimiento_soja_kgxha`) y de la producción total anual (`produccion_soja_t`) para ambos subperíodos. Los resultados consolidados se presentan en la Cuadro 3.

Cuadro 3: Comparación de promedios de rendimiento y producción antes y después de 1996

Período	Rendimiento Promedio (kg/ha)	Producción Promedio (t)
Post-1996 (1996–2024)	2,645, 19	40,454,964
Pre-1996 (1941–1995)	1,457, 71	2,712,400

1.5.2. Analisis

A partir de la comparación entre ambos subperíodos se observan transformaciones estructurales contundentes:

- **Aumento en la Eficiencia Agrícola (kg/ha):** El rendimiento promedio por hectárea aumentó de 1,457, 71 kg/ha en la era pre-transgénica a 2,645, 19 kg/ha en el período post-1996. Esto representa un incremento del **81,46 %** en la productividad media de la tierra.
- **Explosión del Volumen de Producción Total (t):** La producción promedio anual pasó de $2, 71$ millones de toneladas a $40, 45$ millones de toneladas, lo que equivale a un aumento del **1.391,48 %** (multiplicándose por casi 15 veces).

Estos hallazgos confirman de manera empírica que la introducción del paquete tecnológico a partir de 1996 (semilla resistente a glifosato, siembra directa e insumos asociados) no solo generó un salto cuantitativo drástico en la productividad por hectárea, sino que impulsó una masiva expansión de la frontera agrícola.

2. Análisis Econométrico con Datos de Gapminder

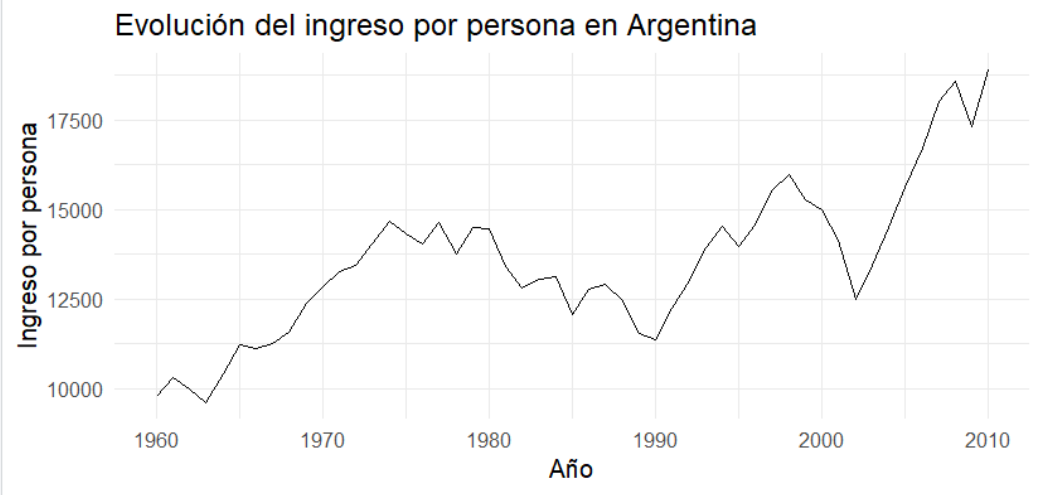
2.1. Parte 1: Ingreso por persona

2.1.1. Inciso 1 - Evolución temporal de la variable income per person en Argentina

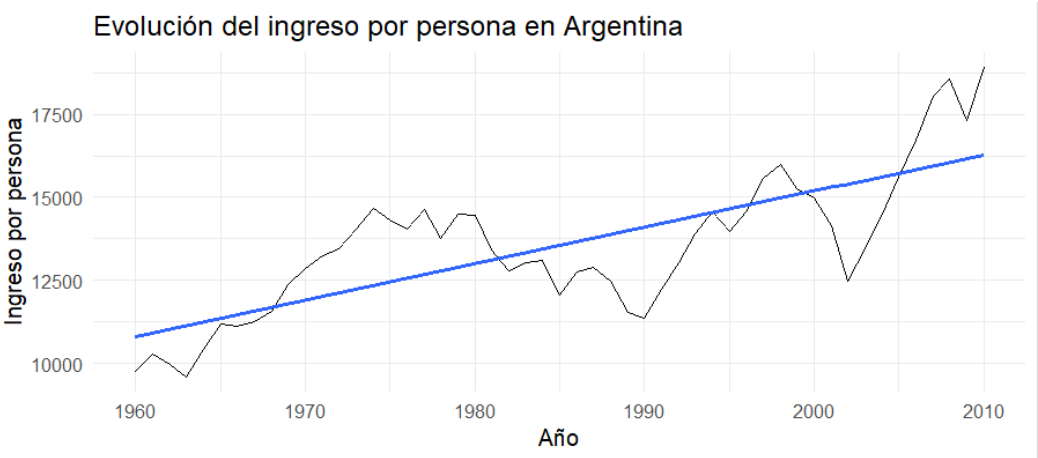
En primer lugar utilizamos `set.seed` y traemos `tidyverse` desde `library`. Luego inspeccionamos el dataframe.

Filtramos el dataframe quedándonos solo con los datos para Argentina y las columnas de país, año e ingreso per cápita. Comprobamos que no hay datos faltantes sumando los NA dentro de la columna `income_per_person`. Luego graficamos usando `ggplot`.

La base va de 1960 a 2010. Encontramos que el ingreso por persona en Argentina durante ese período tiene una tendencia creciente de largo plazo, pero con caídas pronunciadas seguidas por recuperaciones.



Como ayuda visual para mostrar la tendencia utilizamos una regresión lineal que agregamos al `ggplot` con `geom_smooth(method = "lm")`, que deja aún más en evidencia la tendencia creciente en el largo plazo.



2.1.2. Inciso 2 - Modelar dejando afuera los últimos 10 años

Creamos una nueva base a la que denominamos `argentina10`. Como sabemos que el último año de la base es 2010, nos quedamos con los últimos 10 años, es decir, con

el período 2001–2010. Para eso filtramos la columna `year` desde el año máximo menos 9. Estos últimos 10 años corresponden a la parte que más adelante utilizaremos para testear, mientras que los años restantes, a los que denominamos `train`, serán utilizados para entrenar los distintos modelos.

Modelo lineal Tenemos el ingreso per cápita como variable dependiente y los años como variable independiente. Los datos que usamos son los de `train` (1960–2000). El coeficiente que acompaña a los años nos dirá cuánto cambia el ingreso per cápita cuando cambia el año, sin tener en cuenta el error. Consistentemente con lo que habíamos observado a través del gráfico inicial, este coeficiente es mayor a 0, por lo que existe una tendencia creciente ($\beta_1 = 92{,}95$).

Algunos valores útiles son el R-squared, que nos dice cuánto de la variación del ingreso por persona es explicada por el modelo. En este caso no es muy bajo, pero tampoco es extremadamente alto: aproximadamente el 45 % de la variación del ingreso por persona es explicada por el paso de los años.

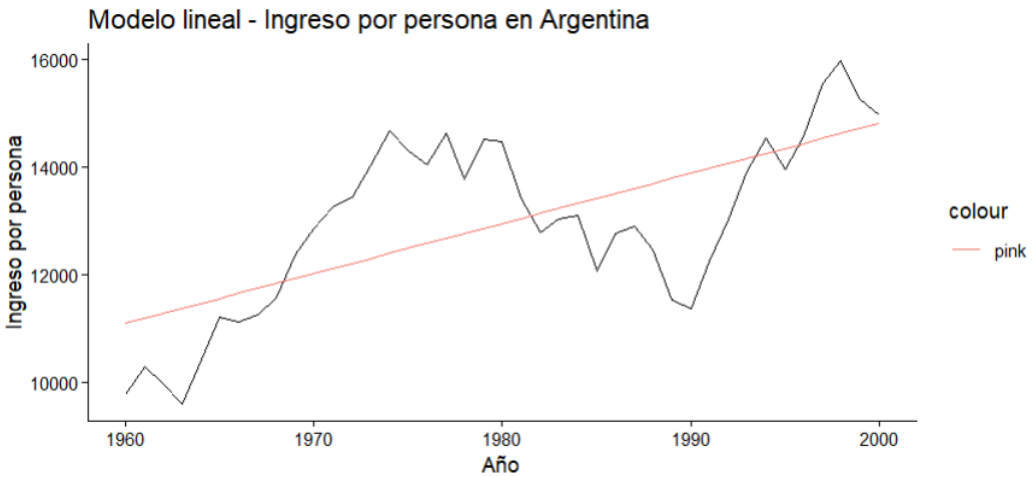
El P-value es extremadamente pequeño, lo que nos indica que el coeficiente tiene significancia estadística. Por lo tanto, hay evidencia de una relación lineal positiva entre el año y el ingreso por persona.

```
Residuals:
    Min      1Q  Median      3Q     Max
-2509.1  -887.6  -213.4  1023.3  2288.1

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) -171079.77   32497.28  -5.264 5.42e-06 ***
year             92.95      16.41   5.663 1.52e-06 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1243 on 39 degrees of freedom
Multiple R-squared:  0.4513,    Adjusted R-squared:  0.4372
F-statistic: 32.07 on 1 and 39 DF,  p-value: 1.521e-06
```

Al final contrastaremos los tres modelos con los datos de los últimos 10 años. Primero contrastamos la predicción del modelo lineal sobre `train` con los datos reales, también de `train`. Para ello generamos predicciones con el modelo lineal usando `predict(modelolineal, newdata = train)`. Luego graficamos por un lado los datos reales y por otro, en rosa, los datos generados con la predicción.



Modelo polinómico de grado 2 Tenemos el ingreso per cápita como variable dependiente y los años como variable independiente, pero en este caso incorporamos además el término del año al cuadrado, `I(year^2)`, por lo que ya no estamos suponiendo que la relación entre ambas variables sea estrictamente lineal. Usamos `summary` para ver las estimaciones de los coeficientes y demás valores.

El coeficiente que acompaña a `year` es positivo, mientras que el coeficiente de `year^2` es negativo. Esto implica que la relación estimada tiene una curvatura cóncava: el ingreso per cápita presenta una tendencia creciente, pero esa tendencia no aumenta a una tasa constante.

El R-squared es aproximadamente 0,498, por lo que el modelo cuadrático explica cerca del 50 % de la variación del ingreso per cápita. Esto representa una mejora respecto del modelo lineal, cuyo R-squared era aproximadamente 0,451.

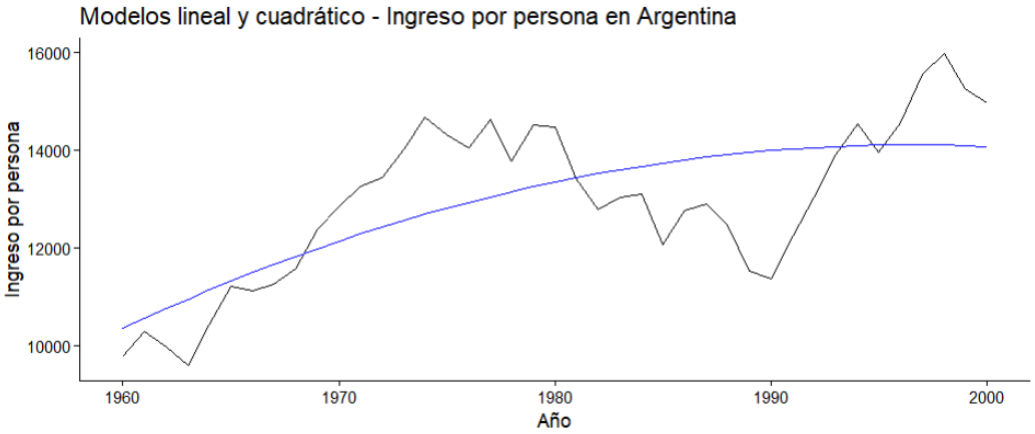
En cuanto a los P-values individuales, tanto el coeficiente de `year` como el de `year^2` tienen valores cercanos a 0,06–0,07, por lo que no resultan estadísticamente significativos al nivel usual del 5 %, aunque se encuentran próximos. Sin embargo, el P-value del test F del modelo es muy pequeño, lo que indica que el modelo considerado en su conjunto tiene significancia estadística.

```
Residuals:
    Min      1Q  Median      3Q     Max
-2622.2  -736.2  -146.4  1021.0  1993.9

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -1.126e+07  5.896e+06  -1.910   0.0637 .
year         1.129e+04  5.956e+03   1.896   0.0655 .
I(year^2)   -2.829e+00  1.504e+00  -1.881   0.0677 .
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1205 on 38 degrees of freedom
Multiple R-squared:  0.498,     Adjusted R-squared:  0.4716
F-statistic: 18.85 on 2 and 38 DF,  p-value: 2.059e-06
```

Nuevamente armamos predicciones de `train` para luego contrastarlas en el gráfico con los datos reales. Usamos `ggplot`, colocando en el eje x los años y en el eje y los datos del período `train` y las predicciones.



Modelo polinómico de grado 10 Tenemos el ingreso per cápita como variable dependiente y los años como variable independiente, pero en este caso permitimos una relación

mucho más flexible utilizando un polinomio de grado 10 y como base de datos `train`. A diferencia de los modelos anteriores, este modelo puede adaptarse mucho más a las distintas subidas y caídas que presenta el ingreso a lo largo del tiempo, al menos durante este período. Vemos los resultados con `summary`.

El R-squared es aproximadamente 0,94, lo que indica que cerca del 94 % de la variación del ingreso por persona dentro de la muestra de entrenamiento es explicada por el modelo. Este valor es considerablemente mayor al obtenido con el modelo lineal y con el modelo cuadrático. El R-squared ajustado también es alto, aproximadamente 0,92.

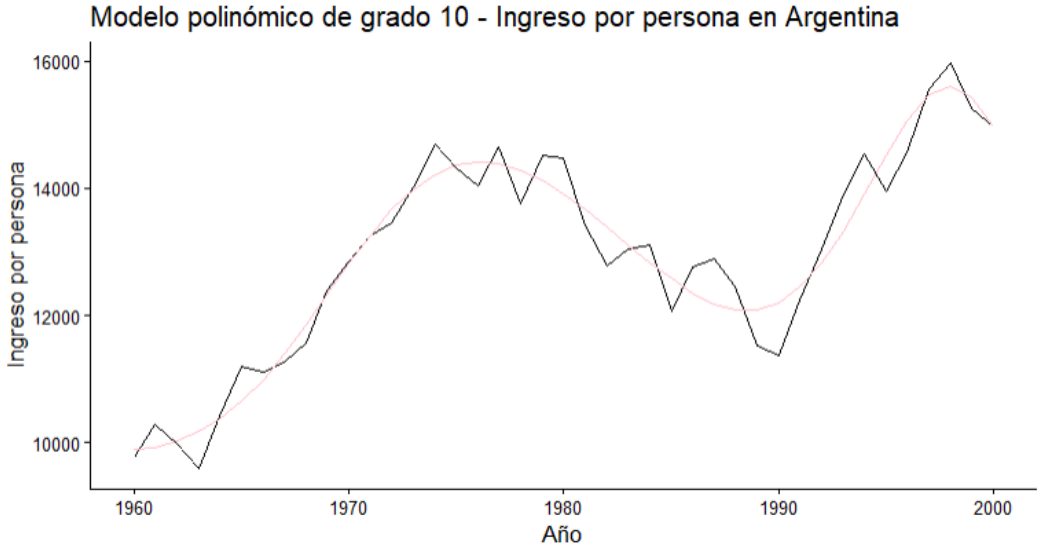
El P-value del test F del modelo es extremadamente pequeño, lo que indica que el modelo considerado en su conjunto tiene significancia estadística. Algunos de los términos polinómicos individuales resultan estadísticamente significativos y otros no, aunque en este caso lo más importante no es interpretar cada coeficiente por separado sino analizar la capacidad de ajuste y, posteriormente, su capacidad para predecir los datos que quedaron fuera de la muestra de entrenamiento.

```
Residuals:
   Min     1Q Median     3Q    Max
-830.1 -238.9    9.5  373.7  711.4

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)     12952.610     71.663 180.743  < 2e-16 ***
poly(year, 10)1  7041.821    458.869  15.346 9.55e-16 ***
poly(year, 10)2 -2265.988    458.869  -4.938 2.77e-05 ***
poly(year, 10)3  5427.527    458.869  11.828 8.00e-13 ***
poly(year, 10)4  1973.707    458.869   4.301 0.000166 ***
poly(year, 10)5 -3611.115    458.869  -7.870 8.79e-09 ***
poly(year, 10)6 -1538.115    458.869  -3.352 0.002182 **
poly(year, 10)7     3.248    458.869   0.007 0.994400
poly(year, 10)8  -131.186    458.869  -0.286 0.776927
poly(year, 10)9   158.404    458.869   0.345 0.732349
poly(year, 10)10  218.333    458.869   0.476 0.637659
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

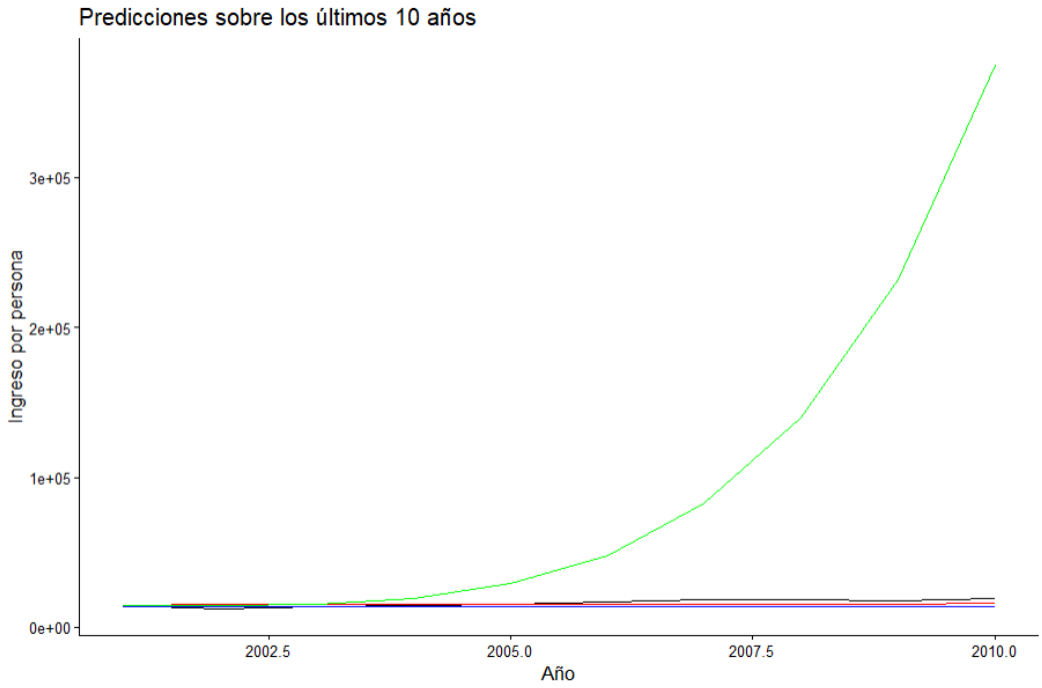
Residual standard error: 458.9 on 30 degrees of freedom
Multiple R-squared:  0.9425,    Adjusted R-squared:  0.9234
F-statistic: 49.19 on 10 and 30 DF,  p-value: 7.68e-16
```

Armamos la predicción con respecto a `train`, para nuevamente contrastarla con los datos reales en el gráfico con `ggplot`.

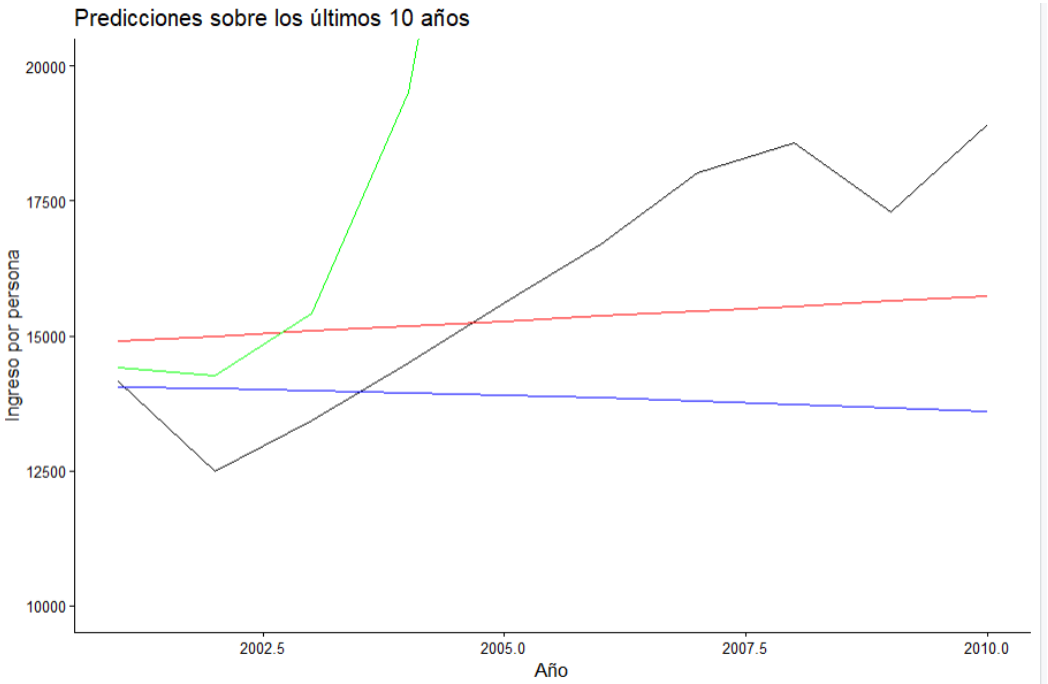


Aquí observamos que la predicción del modelo polinómico se acerca muchísimo a los datos reales, pero veremos posteriormente que esto puede ser contraproducente para aproximar o predecir datos que no pertenezcan a la muestra.

Conclusión sobre el conjunto de test Primero observamos las predicciones de los tres modelos sobre los últimos 10 años en la escala completa.



Luego hacemos "zoom" para poder comparar mejor los modelos lineal y cuadrático con los valores reales.



Verde: modelo polinómico de grado 10.
Azul: modelo polinómico de grado 2.
Rojo: modelo lineal.

Al comparar las predicciones de los tres modelos con los valores reales correspondientes a los últimos 10 años, se observa que los modelos lineal y cuadrático mantienen predicciones relativamente cercanas al rango de los datos observados, aunque ninguno logra reproducir perfectamente la evolución efectiva del ingreso per cápita.

El modelo lineal genera una trayectoria levemente creciente y parece captar razonablemente la tendencia general, aunque subestima los valores observados en buena parte del período. El modelo cuadrático, por su parte, presenta una trayectoria levemente decreciente y también se va alejando de los valores reales, especialmente hacia los últimos años.

El comportamiento más llamativo corresponde al modelo polinómico de grado 10. A pesar de haber presentado un R-squared muy elevado dentro de la muestra de entrenamiento, cercano al 94 %, cuando se lo utiliza para predecir los últimos 10 años sus valores se alejan enormemente de los datos reales. La predicción comienza a crecer de manera cada vez más pronunciada hasta alcanzar valores muy superiores a los efectivamente observados.

Esto muestra que un mejor ajuste dentro de la muestra de entrenamiento no necesariamente implica una mejor capacidad predictiva fuera de ella. En este caso, el resultado es consistente con un problema de sobreajuste: el modelo de grado 10 se adapta muy bien a las fluctuaciones de los datos utilizados para estimarlo, pero esa mejora en el ajuste no se traduce en mejores predicciones sobre datos nuevos.

Usamos Root Mean Squared Error (RMSE) para evaluar las predicciones. Armamos la función `rmse` en el script de funciones y luego la llamamos desde el script principal utilizando el ingreso por persona del conjunto de test y las predicciones correspondientes a cada modelo.

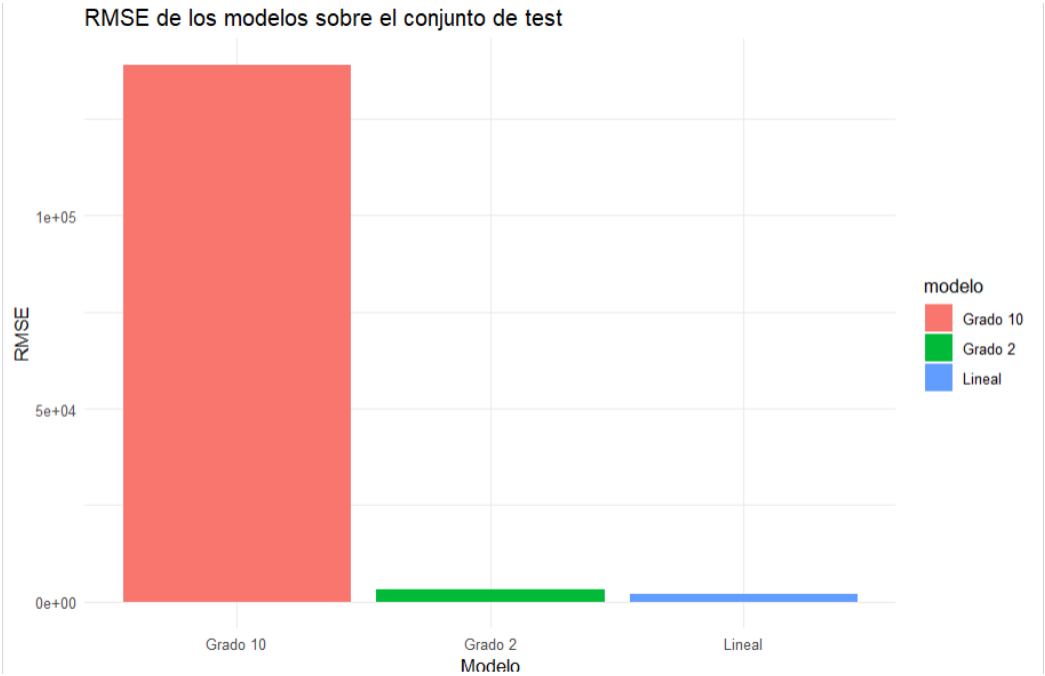
```
> rmselineal
[1] 2012.472
> rmsepoli2
[1] 3114.474
> rmsepoli10
[1] 138836.8
```

El RMSE nos permite medir qué tan lejos están, en promedio, las predicciones de cada modelo respecto de los valores reales de los últimos 10 años. Cuanto menor es este valor, mejor es la capacidad predictiva del modelo.

El modelo lineal presenta el menor RMSE, con un valor aproximado de 2012. El modelo cuadrático tiene un RMSE algo mayor, de aproximadamente 3114. En cambio, el modelo polinómico de grado 10 presenta un RMSE extremadamente elevado, cercano a 138837.

Estos resultados confirman con números lo que ya se observaba en el gráfico. En este caso, el modelo lineal es el que mejor desempeño presenta sobre el conjunto de test, seguido por el modelo cuadrático. El modelo de grado 10, en cambio, muestra un claro problema de sobreajuste.

Lo vemos gráficamente armando un dataframe con los resultados del RMSE de los tres modelos y usando `ggplot` con `geom_bar`.



2.1.3. Inciso 3 - Correlación entre 5 países

a) Correlación entre niveles de ingreso En primer lugar armamos un vector con los 5 países sudamericanos seleccionados para que sea más sencillo filtrar posteriormente. Luego filtramos la base dejando únicamente los países que están dentro del vector que habíamos armado y las columnas de país, año e ingreso por persona. Hacemos un chequeo para ver que quedaron solo los 5 países elegidos usando `unique`.

Necesitamos que cada país quede en una columna, por eso pivoteamos el dataframe. Con todas las columnas de esta base menos la de años calculamos la correlación de la variable de ingreso por persona entre países.

	Argentina	Bolivia	Brazil	Peru	Paraguay
Argentina	1.0000000	0.9244884	0.7951110	0.7816511	0.6733786
Bolivia	0.9244884	1.0000000	0.8445418	0.7664437	0.7099295
Brazil	0.7951110	0.8445418	1.0000000	0.5648635	0.9503120
Peru	0.7816511	0.7664437	0.5648635	1.0000000	0.3572219
Paraguay	0.6733786	0.7099295	0.9503120	0.3572219	1.0000000

b) Correlación entre variaciones porcentuales anuales Ahora hacemos algo similar pero para la variación porcentual del ingreso por país. Retomamos el dataframe que tenía los datos del ingreso de los 5 países y, agrupando por país y con `mutate`, sumamos una columna donde esté la variación porcentual, perdiendo así una observación por país. Usamos el ingreso del período menos el del período anterior, dividido por el ingreso del período anterior, y luego desagrupamos.

Como hicimos antes, pivoteamos y eliminamos la columna de año para poder hacer la matriz de correlación.

	Argentina	Bolivia	Brazil	Peru	Paraguay
Argentina	1.0000000	0.2066589	0.2720522	0.3553164	0.1469514
Bolivia	0.2066589	1.0000000	0.2631619	0.2593245	0.2606822
Brazil	0.2720522	0.2631619	1.0000000	0.4105467	0.4073574
Peru	0.3553164	0.2593245	0.4105467	1.0000000	0.1946716
Paraguay	0.1469514	0.2606822	0.4073574	0.1946716	1.0000000

En la primera matriz analizamos la correlación entre los niveles de ingreso per cápita de los cinco países. En general se observan correlaciones positivas y bastante elevadas. Por ejemplo, Argentina y Bolivia presentan una correlación aproximada de 0,92, mientras que Brasil y Paraguay presentan una de aproximadamente 0,95. Esto indica que, a lo largo del período analizado, los niveles de ingreso de estos países tienden a moverse en una dirección similar. La correlación más baja dentro de esta matriz es la existente entre Perú y Paraguay, que es aproximadamente 0,36.

Sin embargo, cuando analizamos la correlación entre las variaciones porcentuales anuales, los valores disminuyen considerablemente. En este caso las correlaciones continúan siendo positivas, pero son mucho más bajas. Por ejemplo, la correlación entre Argentina y Bolivia pasa de aproximadamente 0,92 en niveles a 0,21 en las variaciones anuales. Algo similar ocurre con el resto de los países. Las mayores correlaciones de crecimiento se observan entre Brasil y Perú, con aproximadamente 0,41, y entre Brasil y Paraguay, también cercana a 0,41.

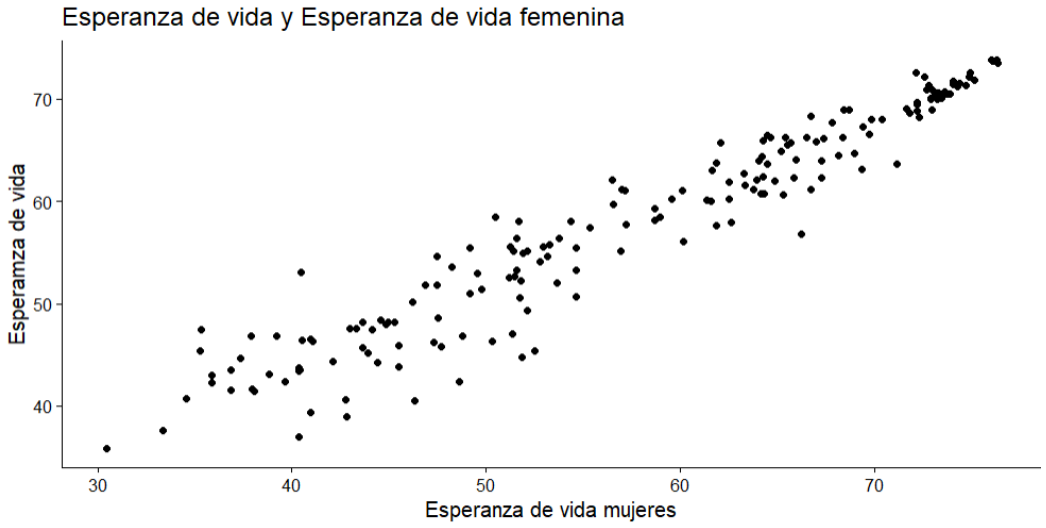
Esta diferencia puede deberse a que los niveles de ingreso de los países presentan una tendencia creciente común a lo largo del tiempo, lo que genera correlaciones elevadas entre las series. Sin embargo, cuando analizamos solamente las variaciones de un año a otro, eliminamos gran parte de esa tendencia y observamos que los movimientos anuales de los ingresos no están tan fuertemente relacionados entre los distintos países.

2.2. Parte 2: Esperanza de vida y género

2.2.1. Inciso 5 - Life expectancy female vs. life expectancy

En primer lugar filtramos el dataframe para quedarnos únicamente con las observaciones correspondientes al año 1965 y seleccionamos las columnas de esperanza de vida general, esperanza de vida femenina, año y país. Luego usamos `sum(is.na())` para comprobar si existían datos faltantes en las dos variables que queríamos analizar.

Como encontramos observaciones con datos faltantes, usamos `filter()` junto con `!is.na()` para conservar únicamente los países que tenían información disponible en ambas variables. También observamos que `life_expectancy_female` estaba almacenada como texto, por lo que utilizamos `mutate()` y `as.numeric()` para convertirla en una variable numérica. Finalmente usamos `ggplot()` con `geom_point()` para realizar un gráfico de dispersión entre la esperanza de vida femenina y la esperanza de vida general.



Observamos, a grandes rasgos, una relación positiva entre ambas variables.

2.2.2. Inciso 6 - Modelo de regresión lineal

Retomamos la base limpia del inciso anterior y estimamos una regresión lineal simple utilizando `lm()`. Tomamos `life_expectancy` como variable dependiente y `life_expectancy_female` como variable independiente. Luego usamos `summary()` para observar los coeficientes estimados, sus P-values, el R-squared y demás resultados del modelo.

```
Residuals:
    Min      1Q  Median      3Q     Max
-8.4672 -1.0312  0.2222  1.5032  8.8593

Coefficients:
                     Estimate Std. Error t value Pr(>|t|)
(Intercept)          12.23839    1.00179   12.22   <2e-16 ***
life_expectancy_female  0.79051    0.01697   46.58   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 2.856 on 182 degrees of freedom
Multiple R-squared:  0.9226,    Adjusted R-squared:  0.9222
F-statistic:  2170 on 1 and 182 DF,  p-value: < 2.2e-16
```

El gráfico muestra una relación positiva y aproximadamente lineal entre la esperanza de vida femenina y la esperanza de vida general. Esto también se observa en la regresión estimada, donde el coeficiente que acompaña a `life_expectancy_female` es aproximadamente 0,79. Esto significa que un aumento de un año en la esperanza de vida femenina está asociado, en promedio, con un aumento de aproximadamente 0,79 años en la esperanza de vida general.

El R-squared es particularmente alto, aproximadamente 0,922. Esto significa que alrededor del 92,2 % de la variación observada en la esperanza de vida general entre los distintos países en 1965 es explicada por el modelo lineal a partir de la esperanza de vida femenina. Por lo tanto, la relación lineal entre ambas variables es muy fuerte y el modelo presenta un elevado poder explicativo.

El P-value asociado al coeficiente de la esperanza de vida femenina es extremadamente bajo, lo que indica que existe evidencia estadística muy fuerte de una relación positiva entre ambas variables.

De todas formas, el elevado R-squared también debe interpretarse teniendo en cuenta que ambas variables están estrechamente relacionadas por su propia definición, ya que la esperanza de vida general incorpora la esperanza de vida de hombres y mujeres. Por este motivo, es razonable encontrar una relación muy fuerte entre ambas.

2.2.3. Inciso 7 - Contraste de hipótesis

Para contrastar si la esperanza de vida femenina es igual a la esperanza de vida general o si es mayor, utilizamos `t.test()`. Como ambas observaciones corresponden al mismo país, indicamos `paired = TRUE`, ya que se trata de datos apareados. Además utilizamos `alternative = "greater"` porque la hipótesis alternativa que queremos contrastar es que la esperanza de vida femenina sea mayor que la esperanza de vida general.

El contraste queda planteado de la siguiente manera:

$$H_0: \texttt{life_expectancy_female} = \texttt{life_expectancy}$$
$$H_1: \texttt{life_expectancy_female} > \texttt{life_expectancy}$$

En el comando colocamos primero `life_expectancy_female` y luego `life_expectancy`, de manera que R evalúe si la diferencia promedio entre ambas variables es mayor que cero.

```
        Paired t-test

data:  lifeexp1965clean$life_expectancy_female and lifeexp1965clean$life_ex
pectancy
t = -0.52094, df = 183, p-value = 0.6985
alternative hypothesis: true mean difference is greater than 0
95 percent confidence interval:
 -0.6188645        Inf
sample estimates:
mean difference
     -0.1482826
```

El resultado del test arroja un estadístico t de aproximadamente -0,52 y un P-value de aproximadamente 0,699. Como el P-value es considerablemente mayor a 0,05, no podemos rechazar la hipótesis nula a favor de la alternativa planteada.

Además, la diferencia promedio estimada entre la esperanza de vida femenina y la esperanza de vida general es aproximadamente -0,148 años. Es decir que, en la muestra correspondiente al año 1965, la esperanza de vida femenina no resulta en promedio mayor que la esperanza de vida general, sino que la diferencia estimada es levemente negativa.

Por lo tanto, con los datos analizados no encontramos evidencia estadística suficiente para sostener que la esperanza de vida femenina sea mayor que la esperanza de vida general en el año 1965.

2.2.4. Inciso 8 - Regresión múltiple

Para estimar la regresión múltiple volvemos a partir del dataframe original porque necesitamos incorporar también `income_per_person`. Filtramos nuevamente el año 1965 y seleccionamos país, esperanza de vida general, esperanza de vida femenina e ingreso por persona. Luego eliminamos las observaciones que presentan NA en alguna de las variables utilizadas y convertimos nuevamente `life_expectancy_female` a formato numérico mediante `mutate()` y `as.numeric()`.

Con esta nueva base estimamos mediante `lm()` una regresión múltiple de `life_expectancy` sobre `income_per_person` y `life_expectancy_female`. Finalmente usamos `summary()` para analizar los coeficientes de ambos regresores, su significancia estadística y el R-squared del modelo.

```
Residuals:
    Min      1Q  Median      3Q     Max
-8.4535 -1.1073  0.2126  1.5200  8.8266

Coefficients:
                      Estimate Std. Error t value Pr(>|t|)
(Intercept)           1.264e+01  1.033e+00  12.235   <2e-16 ***
income_per_person     3.698e-05  2.455e-05   1.506    0.134
life_expectancy_female 7.792e-01  1.852e-02  42.078   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.846 on 181 degrees of freedom
Multiple R-squared:  0.9236,    Adjusted R-squared:  0.9227
F-statistic:  1094 on 2 and 181 DF,  p-value: < 2.2e-16
```

En esta regresión múltiple tenemos a la esperanza de vida general como variable dependiente y a la esperanza de vida femenina y al ingreso por persona como variables

independientes. Al incorporar el ingreso podemos analizar la relación entre la esperanza de vida femenina y la general manteniendo constante el nivel de ingresos de cada país.

El coeficiente de la esperanza de vida femenina es aproximadamente 0,779. Esto significa que, manteniendo constante el ingreso por persona, un aumento de un año en la esperanza de vida femenina está asociado en promedio con un aumento de aproximadamente 0,78 años en la esperanza de vida general. Además, su P-value es extremadamente pequeño, por lo que esta relación continúa siendo estadísticamente significativa aun después de controlar por el nivel de ingresos.

Por otro lado, el coeficiente de `income_per_person` es positivo pero muy pequeño, aproximadamente 0,000037. Esto indica que, manteniendo constante la esperanza de vida femenina, un aumento de una unidad en el ingreso por persona está asociado con un aumento muy pequeño en la esperanza de vida general. Además, su P-value es aproximadamente 0,134, por lo que no resulta estadísticamente significativo a un nivel del 5 %.

El R-squared del modelo múltiple es aproximadamente 0,924, lo que significa que alrededor del 92,4 % de la variación de la esperanza de vida general entre los países es explicada conjuntamente por la esperanza de vida femenina y el ingreso por persona. Sin embargo, este valor es prácticamente igual al obtenido en la regresión simple, cuyo R-squared era aproximadamente 0,922.

Por lo tanto, al controlar por el nivel de ingresos la relación positiva entre la esperanza de vida femenina y la esperanza de vida general prácticamente se mantiene. La incorporación de `income_per_person` aumenta muy poco el poder explicativo del modelo y, además, su coeficiente no resulta estadísticamente significativo. En función de estos resultados, la inclusión de esta variable no parece aportar demasiado al modelo.

2.2.5. Inciso 9 - Modelo lineal múltiple

Para este inciso elegimos algunas variables que creemos que pueden ayudar a explicar la esperanza de vida general. En primer lugar descartamos `life_expectancy_female` porque así lo pide la consigna y también descartamos `life_expectancy_male`, porque al igual que la esperanza de vida femenina forma parte de la esperanza de vida general y estaría muy directamente relacionada con la variable que queremos explicar.

Una de las variables que elegimos es `child_mortality`. La mortalidad infantil está directamente relacionada con las condiciones de vida y de salud de un país, pero no es una parte de la variable dependiente como sí pasa con la esperanza de vida de hombres o mujeres. Por eso creemos que puede servir para explicar diferencias en la esperanza de vida entre países. Esperamos que la relación sea negativa, es decir, que a mayor mortalidad infantil haya menor esperanza de vida.

También elegimos `children_per_woman` porque puede reflejar diferencias demográficas entre países. En principio esperaríamos que los países con más hijos por mujer tengan una menor esperanza de vida, aunque primero queremos ver cuánto se relaciona esta variable con la mortalidad infantil para no estar usando dos variables que expliquen prácticamente lo mismo.

Por último usamos `income_per_person` porque pensamos que un mayor ingreso puede estar relacionado con mejores condiciones de vida. En este caso vamos a usar el logaritmo del ingreso en vez del ingreso directamente, porque creemos que un aumento del ingreso puede tener un efecto más importante cuando el ingreso es bajo que cuando ya es muy alto.

En primer lugar armamos una base de datos con las variables relevantes, agregando con `mutate` la variable `log_income` y eliminando los datos NA. Luego vamos agregando una a

una las variables para ver si aportan a la explicación de la variabilidad de la esperanza de vida y si los estimadores que las acompañan son estadísticamente relevantes. También miramos que nuestras variables explicativas no estén demasiado correlacionadas entre sí, para prestar atención a un posible problema de multicolinealidad.

Usando todas las variables antes mencionadas y la variable que buscamos explicar armamos una matriz de correlación.

```
> correlaciones
                  life_expectancy log_income children_per_woman child_mortality
life_expectancy         1.0000000  0.7091169         -0.7384630      -0.9328149
log_income              0.7091169  1.0000000         -0.5222793      -0.6394000
children_per_woman     -0.7384630 -0.5222793          1.0000000       0.7150063
child_mortality        -0.9328149 -0.6394000          0.7150063       1.0000000
```

La matriz de correlaciones muestra que las tres variables elegidas tienen una relación importante con la esperanza de vida. La relación más importante aparece con `child_mortality`, con una correlación aproximada de -0,93, y es negativa como era de esperarse. `children_per_woman` también tiene una relación negativa relevante, cercana a -0,74, mientras que `log_income` presenta una correlación positiva de aproximadamente 0,71. También vemos que las variables explicativas están correlacionadas entre sí, especialmente `child_mortality` y `children_per_woman`, con una correlación cercana a 0,72, por lo que tendremos que prestar atención a un posible problema de multicolinealidad.

Empezamos modelando con `child_mortality` como única variable explicativa.

```
    Min      1Q  Median      3Q     Max
-9.6618 -2.3647  0.9374  2.3239 11.9447

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)     72.039278   0.489131  147.28   <2e-16 ***
child_mortality -0.096494   0.002763  -34.92   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 3.7 on 182 degrees of freedom
Multiple R-squared:  0.8701,    Adjusted R-squared:  0.8694
F-statistic:  1220 on 1 and 182 DF,  p-value: < 2.2e-16
```

El primer modelo utiliza únicamente `child_mortality` para explicar la esperanza de vida. El coeficiente estimado es aproximadamente -0,096, por lo que una mayor mortalidad infantil está asociada con una menor esperanza de vida. El P-value es extremadamente bajo, por lo que la relación resulta estadísticamente significativa. Además, el R-squared es aproximadamente 0,87, es decir que este modelo con una sola variable explica cerca del 87 % de la variación en la esperanza de vida.

Luego incorporamos como variable explicativa el logaritmo del ingreso, que a pesar de estar levemente menos correlacionado con la esperanza de vida que `children_per_woman`, no está tan relacionado con `child_mortality` como esta última.

```
Residuals:
    Min      1Q  Median      3Q     Max
-9.4435 -2.0589  0.4369  2.2735 10.6126

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)     54.651190   2.937834  18.603  < 2e-16 ***
child_mortality -0.083888   0.003292 -25.481  < 2e-16 ***
log_income       1.874750   0.313046   5.989 1.11e-08 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 3.39 on 181 degrees of freedom
Multiple R-squared:  0.8916,    Adjusted R-squared:  0.8904
F-statistic: 744.5 on 2 and 181 DF,  p-value: < 2.2e-16
```

Al agregar `log_income` al modelo, ambas variables resultan estadísticamente significativas. El coeficiente de `child_mortality` sigue siendo negativo, aproximadamente -0,084, mientras que el de `log_income` es positivo, aproximadamente 1,87. Esto indica que, manteniendo constante la otra variable, una mayor mortalidad infantil se asocia con una menor esperanza de vida y un mayor ingreso con una mayor esperanza de vida. El R-squared aumenta de aproximadamente 0,87 a 0,892, por lo que la incorporación del ingreso mejora el poder explicativo del modelo.

Finalmente incorporamos la tercera variable, prestando especial atención a su correlación con `child_mortality`.

```
    Min      1Q  Median      3Q     Max
-8.7929 -1.5627  0.4127  1.9396  9.7392

Coefficients:
                   Estimate Std. Error t value Pr(>|t|)
(Intercept)        58.278719   3.019640  19.300  < 2e-16 ***
child_mortality    -0.075707   0.003919 -19.319  < 2e-16 ***
log_income          1.741850   0.305483   5.702 4.78e-08 ***
children_per_woman -0.683184   0.190197  -3.592 0.000423 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 3.283 on 180 degrees of freedom
Multiple R-squared:  0.8989,    Adjusted R-squared:  0.8972
F-statistic: 533.3 on 3 and 180 DF,  p-value: < 2.2e-16
```

Al agregar `children_per_woman` al modelo, las tres variables continúan siendo estadísticamente significativas. El coeficiente de `children_per_woman` es negativo, aproximadamente -0,68, lo que indica que, manteniendo constantes la mortalidad infantil y el ingreso, una mayor cantidad de hijos por mujer está asociada con una menor esperanza de vida. El coeficiente de `child_mortality` sigue siendo negativo y el de `log_income` continúa siendo positivo.

El R-squared aumenta de aproximadamente 0,892 a 0,899 y el R-squared ajustado queda en aproximadamente 0,897. Por lo tanto, la incorporación de `children_per_woman` mejora el poder explicativo del modelo, aunque la mejora es relativamente pequeña. De todas formas, como su P-value es muy bajo, parece aportar información adicional aun teniendo en cuenta las otras dos variables.

Al comparar los tres modelos vemos que a medida que agregamos variables aumenta el poder explicativo. El primer modelo, utilizando solamente `child_mortality`, tenía un R-squared de aproximadamente 0,87. Al agregar `log_income` aumenta a aproximadamente 0,892 y, finalmente, al incorporar `children_per_woman` alcanza aproximadamente 0,899.

Si bien el aumento del R-squared al agregar la tercera variable no es muy grande, `children_per_woman` continúa siendo estadísticamente significativa incluso controlando por mortalidad infantil e ingreso. Además, el R-squared ajustado también aumenta, pasando de aproximadamente 0,890 en el modelo de dos variables a 0,897 en el modelo de tres variables. Por este motivo elegimos como modelo final el que incluye `child_mortality`, `log_income` y `children_per_woman`.

Los signos de los tres coeficientes también son consistentes con lo que esperábamos: una mayor mortalidad infantil y una mayor cantidad de hijos por mujer están asociadas con una menor esperanza de vida, mientras que un mayor ingreso está asociado con una mayor esperanza de vida.

3. Ejercicio 3: Simulación de Demanda de Bienes con Preferencias Cobb-Douglas

3.1. Marco Teórico y Funciones Modulares

En esta sección se analiza el comportamiento de consumo de una población de hogares expuestos a variaciones en sus ingresos y precios de mercado. Se asume que las preferencias de los consumidores están representadas por una función de utilidad de tipo Cobb-Douglas:

$$U(x_1, x_2) = x_1^{\alpha_1} x_2^{\alpha_2}, \quad \text{con } \alpha_1, \alpha_2 \in (0, 1) \text{ y } \alpha_1 + \alpha_2 = 1 \tag{2}$$

Sujeto a la restricción presupuestaria $p_1 x_1 + p_2 x_2 \leq Y$, la resolución analítica del problema de maximización de la utilidad deriva en las funciones de demanda óptima (x_1^*, x_2^*) y la función de utilidad indirecta (U^*):

$$x_1^* = \frac{\alpha_1 Y}{p_1}, \qquad x_2^* = \frac{\alpha_2 Y}{p_2}, \qquad U^* = (x_1^*)^{\alpha_1} (x_2^*)^{\alpha_2} \tag{3}$$

Para llevar a cabo los experimentos de simulación Monte Carlo, se implementaron de manera modular las funciones generadoras en R dentro del script `funciones_cobb.R`.

3.2. Inciso 1: Generación Estocástica de Ingresos (`simular_ingreso`)

Para simular la distribución del ingreso mensual (Y) de una muestra de n hogares, se definió la función `simular_ingreso(n, k)`. La generación de los datos se realiza mediante la distribución Chi-cuadrado (χ_k^2), donde el argumento `df = k` representa los grados de libertad (*degrees of freedom*):

- **Propiedades Estadísticas:** La distribución Chi-cuadrado garantiza valores estrictamente positivos $(Y > 0)$ y presenta un sesgo a la derecha (asimetría positiva), reproduciendo adecuadamente la concentración empírica de la distribución de ingresos en una población.
- **Parámetros Teóricos:** El valor esperado del ingreso simulado es $E[Y] = k$, mientras que su varianza está dada por $Var(Y) = 2k$.

3.3. Inciso 2: Calculador de Demanda Óptima y Utilidad Indirecta (`demanda_cd`)

Se programó la función `demanda_cd(Y, p1, p2, alpha1, alpha2)` para computar de forma vectorizada las asignaciones óptimas de consumo y el bienestar derivado. La función recibe como insumos el vector de ingresos (Y), los precios vigentes de mercado (p_1, p_2) y los parámetros de preferencia (α_1, α_2).

A partir de dichos insumos, se evalúan las ecuaciones:

$$x_1^* = \frac{\alpha_1 \cdot Y}{p_1} \tag{4}$$

$$x_2^* = \frac{\alpha_2 \cdot Y}{p_2} \tag{5}$$

$$U^* = (x_1^*)^{\alpha_1} \cdot (x_2^*)^{\alpha_2} \tag{6}$$

Para garantizar un manejo eficiente de las observaciones y permitir la integración directa con el paquete `ggplot2`, la función consolida y retorna un objeto de tipo `tibble` estructurado con las columnas `x1_opt`, `x2_opt` y `u_opt`.

3.4. Inciso 3: Simulación Base, Medias, Cuartiles y Densidades Empíricas

Para llevar a cabo el experimento base, se simuló el comportamiento de consumo de una población heterogénea de $N = 10{,}000$ hogares utilizando un parámetro de grados de libertad $k = 20$ en la generación de ingresos estocásticos. Los parámetros fijados para el mercado y la estructura de preferencias se detallan a continuación:

- **Grados de libertad del ingreso:** $k = 20$ (implica una media teórica $E[Y] = 20$ y varianza $Var(Y) = 40$).
- **Precios de Mercado:** $p_1 = 5$ y $p_2 = 7$.
- **Parámetros de Preferencia:** $\alpha_1 = 0,3$ y $\alpha_2 = 0,7$ (cumpliendo $\alpha_1 + \alpha_2 = 1$).

3.4.1. Estadísticos Descriptivos: Medias y Cuartiles

En el Cuadro 4 se presentan los estadísticos descriptivos actualizados obtenidos a partir del comando `summary(simu_prueba)` para las demandas óptimas (x_1^*, x_2^*) y la utilidad indirecta (U^*), garantizando la total reproducibilidad mediante la semilla `set.seed(345)`:

Cuadro 4: Resumen estadístico de la simulación base de prueba ($N = 10{,}000$)

Variable	Mínimo	Q1 (25 %)	Mediana	Media	Q3 (75 %)	Máximo
Demanda Bien 1 (x_1^*)	0,2460	0,9263	1,1684	1,2011	1,4239	3,2852
Demanda Bien 2 (x_2^*)	0,4101	1,5438	1,9474	2,0018	2,3731	5,4754
Utilidad Indirecta (U^*)	0,3518	1,3245	1,6707	1,7174	2,0359	4,6974

Verificación Analítica y Proporcionalidad: A partir de los resultados empíricos se verifica la consistencia teórica de las demandas Marshallianas Cobb-Douglas:

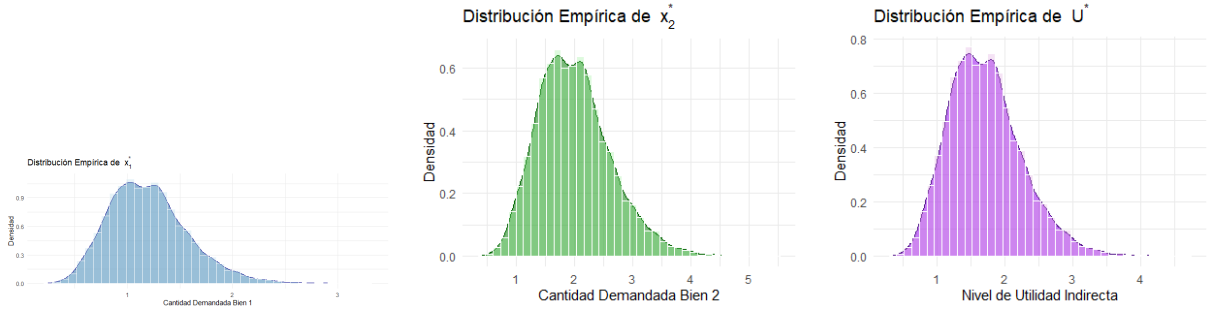
1. **Proporcionalidad en el gasto:** Con $\alpha_1 = 0,3$ y $p_1 = 5$, la demanda promedio estimada es $\bar{x}_1^* = 1,2011$, lo que implica un gasto medio de $p_1 \cdot \bar{x}_1^* = 5 \times 1,2011 = 6,0055$. Para el bien 2 ($\alpha_2 = 0,7$ y $p_2 = 7$), la demanda media es $\bar{x}_2^* = 2,0018$, representando un gasto medio de $p_2 \cdot \bar{x}_2^* = 7 \times 2,0018 = 14,0126$. El gasto total promedio suma $\bar{Y} \approx 20,018$, consistente con la media teórica $E[Y] = k = 20$.

2. **Relación entre Media y Mediana:** En las tres variables, la media supera ligeramente a la mediana (por ejemplo, en x_1^*: $1,2011 > 1,1684$), confirmando la asimetría positiva heredada de la distribución Chi-cuadrado.

3.4.2. Análisis de las Distribuciones Empíricas

Las funciones de densidad empírica reflejan la estructura teórica del modelo:

- **Asimetría Positiva:** Existe una mayor densidad de probabilidad en los niveles bajos e intermedios de consumo, con una cola derecha extendida que representa a los hogares con mayores ingresos (alcanzando máximos de $x_1^* = 3,2852$ y $U^* = 4,6974$).



(a) Demanda x_1^* (b) Demanda x_2^* (c) Utilidad U^*

Figura 2: Distribuciones empíricas de densidad para x_1^*, x_2^* y U^* en la simulación base.

3.5. Inciso 4: Función para la Probabilidad de Bajo Consumo (`prob_bajo_consumo`)

Se programó la función modular `prob_bajo_consumo(demanda_vector, umbral_c)` para calcular la frecuencia relativa de hogares cuya demanda de un bien queda por debajo de un umbral de consumo mínimo $c \in \mathbb{R}^+$:

$$\hat{P}(x < c) = \frac{1}{N} \sum_{i=1}^{N} \mathbb{I}(x_i < c) \tag{7}$$

3.5.1. Prueba de Funcionamiento de la Función

Dado que el valor c es un parámetro libre fijado según el criterio de análisis o la línea de pobreza/subsistencia elegida, se evaluó la función a modo ilustrativo sobre la simulación base fijando un umbral de prueba $c = 2$:

- **Bien 1 (x_1^*):** `prob_bajo_consumo(simu_base$x1_opt, umbral_c = 2)` $\rightarrow$ calcula el porcentaje de hogares con $x_1^* < 2$.
- **Bien 2 (x_2^*):** `prob_bajo_consumo(simu_base$x2_opt, umbral_c = 2)` $\rightarrow$ calcula el porcentaje de hogares con $x_2^* < 2$.

Esta estructura modular permite adaptar de manera flexible el cálculo a cualquier escenario de políticas públicas o metas de consumo mínimo en etapas posteriores del análisis.

3.6. Incisos 5 y 6: Shock de Precios, Densidades Comparadas y Pérdida de Bienestar

Se evaluó el impacto de un shock exógeno de precios en el que el precio del bien 1 (p_1) se incrementa un 20 % (pasando de $p_1 = 5$ a $p_1' = 6$), manteniendo constantes el precio del segundo bien ($p_2 = 7$), la ponderación de las preferencias ($\alpha_1 = 0,3$; $\alpha_2 = 0,7$) y la distribución subyacente de ingresos de la población ($Y \sim \chi^2_{20}$).

3.6.1. Cuadro Comparativo Pre vs. Post Shock

En el Cuadro 5 se presentan los resultados numéricos promedio obtenidos antes y después del incremento de precios, garantizando reproducibilidad mediante la semilla `set.seed(345)`:

Cuadro 5: Impacto del shock de precios (+20 % en p_1) sobre el consumo y el bienestar

Escenario	**Demanda Promedio (x_1^*)**	**Utilidad Promedio (U^*)**	**Hogares con $x_1^* <$**
Pre-Shock ($p_1 = 5$)	1,20	1,72	96,8 %
Post-Shock ($p_1 = 6$)	1,00	1,63	99,5 %
Variación	**-16,67 %**	**-5,23 %**	**+2,70 p.p.**

3.6.2. Discusión Económica de los Resultados

A partir de las simulaciones y la visualización de las curvas de densidad superpuestas (Figura 3), se destacan tres hallazgos principales:

1. **Contracción Proporcional del Consumo:** La demanda media del bien 1 disminuyó de 1,20 a 1,00 unidades. Dado que las funciones de demanda Marshalliana para preferencias Cobb-Douglas se definen como $x_1^* = \frac{\alpha_1 Y}{p_1}$, un aumento del 20 % en el precio ($p_1' = 1,2p_1$) reduce contractivamente la cantidad consumida en un factor $\frac{1}{1,2} \approx 16,67\,\%$ de forma homogénea sobre toda la distribución.
2. **Aumento de la Masa de Hogares en Bajo Consumo:** El desplazamiento de la curva de densidad hacia la izquierda empuja masa probabilística hacia los tramos inferiores de consumo. Fijando el umbral de vulnerabilidad en $c = 2$, la proporción de hogares por debajo de dicho nivel se eleva del 96,8 % al 99,5 %, dejando a la casi totalidad de la población simulada bajo la línea de consumo de referencia.

3. **Deterioro en la Utilidad Indirecta Promedio (U^*):** La utilidad indirecta promedio de la población disminuyó de 1,72 a 1,63 unidades, lo que equivale a una pérdida neta de bienestar general del 5,23 % derivada exclusivamente del encarecimiento del bien 1.

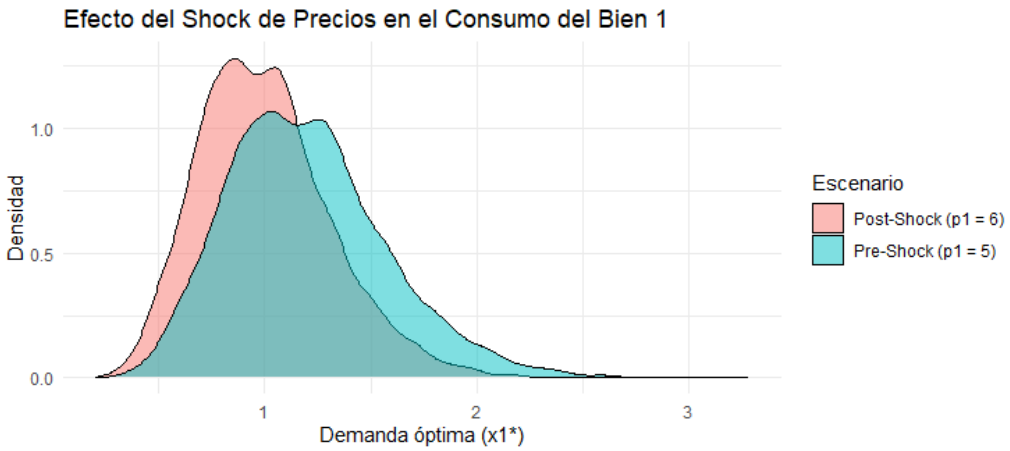


Figura 3: Distribuciones de densidad superpuestas de la demanda óptima del bien 1 (x_1^*) antes ($p_1 = 5$) y después ($p_1 = 6$) del shock de precios.

3.7. Inciso 7: Heterogeneidad en Preferencias y Sensibilidad al Shock de Precios

Para incorporar heterogeneidad en las preferencias de la población, se asumió que la participación presupuestaria destinada al bien 1 (α_1) varía estocásticamente entre los hogares según una distribución Beta:

$$\alpha_1 \sim \text{Beta}(a = 2, b = 3), \quad \alpha_2 = 1 - \alpha_1 \tag{8}$$

Bajo esta parametrización, el valor esperado de la preferencia por el bien 1 es $E[\alpha_1] = \frac{a}{a+b} = \frac{2}{2+3} = 0,40$, lo que introduce dispersión en los gustos alrededor de una preferencia promedio más elevada que en el caso homogéneo ($\alpha_1 = 0,3$).

3.7.1. Resumen Estadístico Pre-Shock

En el Cuadro 6 se presentan las métricas descriptivas obtenidas en la simulación base con heterogeneidad en preferencias ($N = 10{,}000$, $p_1 = 5$, $p_2 = 7$), garantizando reproducibilidad mediante `set.seed(345)`:

Cuadro 6: Resumen estadístico con heterogeneidad en preferencias ($\alpha_1 \sim \text{Beta}(2, 3)$)

Variable	Mínimo	Q1 (25 %)	Mediana	Media	Q3 (75 %)	Máximo
Demanda Bien 1 (x_1^*)	0,0320	0,8651	1,4176	1,6015	2,1541	7,4838
Demanda Bien 2 (x_2^*)	0,0745	1,1202	1,6250	1,7158	2,2071	6,9307
Utilidad Indirecta (U^*)	0,4050	1,3900	1,7630	1,8350	2,1860	6,3900

3.7.2. Impacto del Shock de Precios con Heterogeneidad

Se evaluó el mismo incremento exógeno de precios (+20 % en p_1, pasando de 5 a 6). Los resultados numéricos promedio antes y después del shock se resumen en el Cuadro 7:

Cuadro 7: Efecto del shock de precios ($p_1 = 5 \rightarrow p_1 = 6$) con preferencias heterogéneas

Escenario	**Demanda Promedio (x_1^*)**	**Utilidad Promedio (U^*)**	**Hoga**
Pre-Shock Heterogéneo ($p_1 = 5$)	1,60	1,83	
Post-Shock Heterogéneo ($p_1 = 6$)	1,33	1,71	
Variación	**-16,88 %**	**-6,56 %**	

3.7.3. Comparación con el Caso Homogéneo y Análisis de Sensibilidad

Al comparar el escenario heterogéneo con el caso homogéneo ($\alpha_1 = 0,3$ constante), se identifican importantes diferencias analíticas:

1. **Respuesta de la Demanda Promedio ($\bar{x}_1^*$):** La demanda media cae de 1,60 a 1,33 unidades (una reducción del -16,88 %), consistente con la elasticidad precio unitaria de las demandas Marshallianas Cobb-Douglas ($x_1^* = \frac{\alpha_1 Y}{p_1}$), donde el impacto agregado refleja el promedio de la preferencia poblacional $E[\alpha_1] = 0,40$.

2. **Mayor Dispersión en la Distribución:** La variabilidad en el consumo ya no responde únicamente a la desigualdad del ingreso (Y), sino también a la dispersión estocástica de α_1. Esto expande el rango de consumo alcanzando máximos de $x_1^* = 7,4838$ y $U^* = 6,3900$.

3. **Sensibilidad de la Masa en Bajo Consumo ($x_1^* < 2$):** En el caso homogéneo, la proporción de hogares por debajo de $c = 2$ estaba saturada (96,8 %), variando solo +2,70 p.p. post-shock. Bajo heterogeneidad, la masa inicial es de 71,0 % y salta a 81,0 % tras el shock (un incremento significativo de +10,00 p.p.), demostrando una mayor sensibilidad de la vulnerabilidad poblacional ante aumentos de precios.

4. **Mayor Sensibilidad del Bienestar (U^*):** La utilidad promedio se reduce de 1,83 a 1,71 unidades (una contracción del -6,56 %). La dispersión en las preferencias acentúa la penalización en el bienestar general, afectando con mayor dureza a los hogares que asignan una mayor ponderación al bien encarecido.

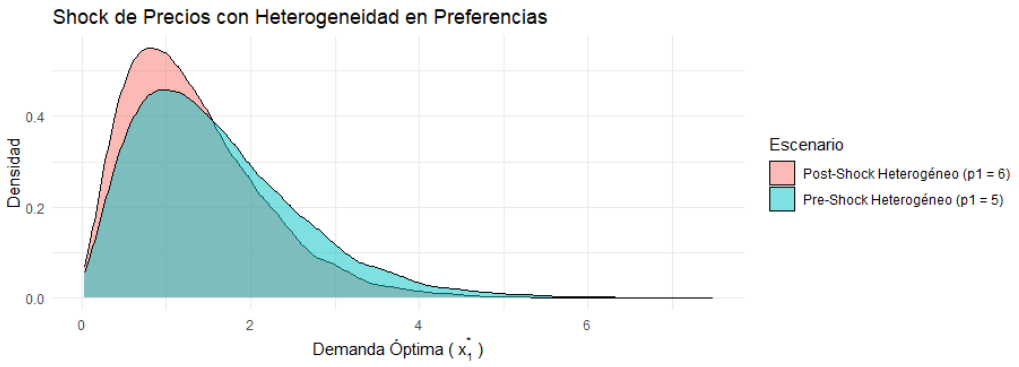


Figura 4: Distribuciones de densidad superpuestas de la demanda óptima del bien 1 (x_1^*) pre y post shock bajo preferencias heterogéneas ($\alpha_1 \sim \text{Beta}(2, 3)$).